

AI Loadboard — технічна документація

Архітектура системи, доменна модель, AI-підсистема та інженерні рішення — від того, що вже працює, до того, що спроектовано на масштаб.

Версія документа **0.1** Дата **16.08.2026** Статус продукту **MVP / демо**

Пов'язаний документ **Project Overview (для інвесторів)**

01 Про документ

Це технічна специфікація проекту AI Loadboard — вантажної біржі з прямим з'єднанням вантажовідправника і перевізника, без брокера-посередника. На відміну від інвесторського огляду (`project-documentation.html`), тут немає маркетингового спрощення: документ описує систему так, як її бачить інженерна команда — включно з тим, що ще не побудовано.

Аудиторія: технічні співзасновники, майбутні інженери, що приєднуються до команди, і технічний due diligence з боку інвестора.

Кожен розділ і кожен рядок таблиці позначені міткою зрілості:

MVP · ГОТОВО — реалізовано і працює в поточному демо-каркасі · **ФАЗА 2** — у найближчому спринті розробки · **ФАЗА 3** — заплановано, дизайн ще не заморожений · **R&D** — потребує дослідження/прототипування моделі перед комітом у продукт · **РИЗИК** — відомий технічний борг або відкрите питання.

Документ навмисно не приховує незрілість поточної кодової бази: MVP — це навмисно спрощений транзакційний каркас (реєстрація → публікація вантажу → взяття вантажу → завершення), без жодної AI-функції, зібраний, щоб перевірити базовий цикл shipper↔carrier до інвестиції в ML-шар.

02 Огляд системи та рівень зрілості

AI Loadboard — двостороння платформа: вантажовідправник публікує вантаж, перевізник бачить його і бере напряду, без брокера. Довгострокове бачення — не лише дошка оголошень, а система, де AI виконує роботу диспетчера й брокера: підбирає вантаж, прогнозує ставку, веде перші переговори, перевіряє контрагента і обробляє документи.


КОМПОНЕНТ	ПОТОЧНИЙ СТАН (MVP)	ЦІЛЬОВИЙ СТАН
Клієнт	React SPA з клієнтським роутингом (<code>react-router</code>): маркетингова головна, список вантажів, сторінка деталей вантажу, сторінка документації, ручний <code>fetch</code>	React SPA + мобільний застосунок (React Native), кешування запитів, realtime через WebSocket
Бекенд	Один монолітний FastAPI-сервіс	Core-сервіс + вісім AI-сервісів, розв'язаних через шину подій
База даних	Один PostgreSQL, 3 таблиці (<code>users</code> , <code>loads</code> , <code>refresh_tokens</code>), схема під Alembic-міграціями	PostgreSQL (OLTP) + pgvector/векторна БД + Redis (кеш/черги) + об'єктне сховище документів
Автентифікація	Email + пароль, короткоживучий JWT (15 хв) + revocable refresh-токен з ротацією (розділ 9)	Refresh-токен в httpOnly cookie замість <code>localStorage</code> , MFA, SSO для enterprise-акаунтів
Матчинг вантажів	MVP: детерміністична евристика під історію перевізника (розділ 7.3)	ML-ранжування під профіль перевізника
AI-функції	3 з 7 — NL Search, Smart Matching і ETA, усі MVP без ML/embeddings (розділи 7.3/7.6/7.7)	7 AI-сервісів (розділ 7)
Інфраструктура	Docker Compose, один хост	Kubernetes, кілька середовищ, автоскейлінг
Спостережуваність	Немає — лише логи <code>uvicorn</code> у stdout	Метрики, трейсинг, структуровані логи, алертинг, AI-eval пайплайни

Навмисне рішення, не недогляд. AI не додається «зверху» на готову дошку оголошень — уся архітектура нижче спроектована так, щоб AI-сервіси підключалися як окремі, незалежно деплойовані споживачі подій, а не як виклики всередині монолітного контролера. Це головна архітектурна ставка проекту.

03 Архітектура верхнього рівня

Система розділена на дві половини з різними вимогами до надійності й латентності. **Core Loadboard Service** — транзакційне ядро (реєстрація, вантажі, статуси, платежі в майбутньому): має

бути швидким, консистентним, з жорсткими SLA. **AI-сервіси** — обчислювально важкі, залежать від зовнішніх LLM/ML-провайдерів, можуть відповідати з затримкою в секунди і не повинні бути транзакційним шляхом. Тому вони зв'язані асинхронно через шину подій, а не прямими синхронними викликами.



Легенда: суцільна лінія — синхронний запит; пунктир — асинхронний результат, що повертається клієнту.

Мал. 1 — Транзакційне ядро і AI-сервіси розв'язані шиною подій: Core пише у Postgres і публікує подію, AI-сервіси споживають її асинхронно й повертають результат клієнту окремим каналом (WS/поллінг), не блокуючи основний запит.

Наразі реалізований лише прямокутник **Core Loadboard Service** ↔ **PostgreSQL** у верхній половині схеми — без API Gateway, без шини подій, без жодного AI-сервісу. Решта — цільова архітектура, під яку вже зараз проектується доменна модель (розділ 5) і контракти подій.

Чому шина подій, а не прямі виклики

- **Ізоляція збоїв.** Якщо LLM-провайдер деградує чи впав, публікація вантажу і взяття вантажу продовжують працювати — це різні відмовостійкі домени.
- **Незалежне масштабування й деплой.** Negotiation Agent можна викотити окремо від Core, дати йому свій пул воркерів і GPU/API-бюджет, не чіпаючи транзакційний код.
- **Заміна моделі без даунтайму ядра.** Провайдер LLM або алгоритм скорингу можна змінити, підключивши нову версію споживача до тієї самої події.

- **Аудит за замовчуванням.** Кожна подія — це запис у журналі: хто що запропонував і коли. важливо для спорів «AI щось пообіцяв контрагенту».

04 Технологічний стек

Клієнт

ТЕХНОЛОГІЯ	РОЛЬ	СТАТУС
React 18 + TypeScript	SPA, компонентний UI	MVP
Vite	Dev-сервер і білд	MVP
Ручний <code>fetch</code> + React Context	Доступ до API та стан автентифікації (<code>AuthContext.tsx</code>)	MVP
react-router-dom	Клієнтський роутинг — список вантажів (<code>/</code>) і сторінка деталей (<code>/loads/:id</code>)	MVP
Leaflet + CARTO Voyager tiles	Мапа на сторінці деталей вантажу — маркери origin/destination і приблизний маршрут	MVP
OpenStreetMap Nominatim	Геокодування origin/destination у координати — безкоштовно, без ключа (<code>frontend/src/geocode.ts</code>)	MVP
OSRM (публічний demo-сервер)	Реальний маршрут по дорогах, дистанція й час у дорозі — безкоштовно, без ключа (<code>frontend/src/routing.ts</code>); фолбек на пряму лінію, якщо недоступний	MVP
TanStack Query	Кешування запитів, повторні спроби, інвалідація	ФАЗА 2
WebSocket-клієнт	Realtime-оновлення статусів вантажу, офери AI-агента	ФАЗА 2
React Native	Мобільний застосунок для перевізників (сповіщення, GPS)	ФАЗА 3

Бекенд і дані

ТЕХНОЛОГІЯ	РОЛЬ	СТАТУС
Python 3.12 + FastAPI	REST API, валідація через Pydantic	MVP
SQLAlchemy 2.x	ORM, декларативні моделі	MVP
PostgreSQL 16	Основне сховище (OLTP)	MVP
python-jose + passlib/bcrypt	JWT, хешування паролів	MVP
Redis	Кеш сесій, rate-limit лічильники, черга задач (Celery/RQ broker)	ФАЗА 2
pgvector (розширення Postgres)	Векторний пошук для NL-запитів та матчингу — старт без окремої векторної БД	ФАЗА 2
Kafka / Redis Streams	Шина подій між Core і AI-сервісами	ФАЗА 3
S3-сумісне об'єктне сховище	Зберігання документів (BOL/POD/rate confirmation)	ФАЗА 2
Alembic	Міграції схеми БД — застосовуються перед стартом застосунку (backend/entrypoint.sh у Docker, CI-крок, автотест-фікстура), не самим застосунком	MVP
httpx	Синхронні HTTP-виклики до Nominatim/OSRM з бекенда — ETA MVP (core/eta.py , розділ 7.7)	MVP

AI / ML

ТЕХНОЛОГІЯ	РОЛЬ	СТАТУС
Claude Haiku 4.5 (structured outputs)	Екстракція структурованого фільтра з вільного текстового запиту — NL Search (розділ 7.6)	MVP
LLM Gateway (LiteLLM-подібний шар)	Єдина точка виклику моделей різних провайдерів, з фолбеком і лічильником вартості	R&D
Claude / GPT-клас моделей (function calling)	Negotiation Agent, структурування документів	R&D
Sentence-embedding модель (напр. клас <code>bge</code> / <code>e5</code>)	Векторизація вантажів і запитів для матчингу й пошуку	R&D
Gradient boosting (LightGBM/XGBoost)	Прогноз ринкової ставки, ETA, trust-скоринг — табличні дані, пояснюваність важливіша за глибокі мережі	R&D
OCR + layout-модель (напр. клас LayoutLM/Texttract)	Розпізнавання BOL/POD/rate confirmation	R&D
MLflow / реєстр моделей	Версіонування моделей, відтворюваність	ФАЗА 3

Інфраструктура та спостережуваність

ТЕХНОЛОГІЯ	РОЛЬ	СТАТУС
Docker + Docker Compose	Локальний запуск трьох контейнерів (db/backend/frontend)	MVP
Kubernetes (керований — EKS/GKE)	Оркестрація в проді, автоскейлінг AI-воркерів окремо від Core	ФАЗА 3
GitHub Actions	CI: лінт, тести, білд образів, деплой	ФАЗА 2
Terraform	Інфраструктура як код (мережа, БД, кластер)	ФАЗА 3
OpenTelemetry + Prometheus/Grafana	Метрики й трейсинг наскрізних запитів, включно з AI-викликами	ФАЗА 3
Sentry	Трекінг помилок фронтенду і бекенду	ФАЗА 2

05 Доменна модель даних

Поточна схема — дві таблиці, свідомо мінімальні для MVP:

```
-- backend/app/models.py — те, що реально існує сьогодні

users(id, email UNIQUE, hashed_password, company_name,
      role ENUM(shipper|carrier), created_at)

loads(id, title, origin, destination, equipment_type DEFAULT 'Dry Van',
      weight_lbs, price_usd NUMERIC(10,2),
      shipper_id FK→users NULLABLE, carrier_id FK→users NULLABLE,
      shipper_name, carrier_name NULLABLE,
      status ENUM(open|accepted|completed), created_at, accepted_at NULLABLE)
```

Вирішено (достроково, ще у Фазі MVP): `loads` тепер має `shipper_id` / `carrier_id` як FK на `users` — вантаж пов'язаний з автентифікованим користувачем, який його опублікував чи взяв, і саме на це посилання спираються перевірки власності на рівні API (розділ 8). `shipper_name` / `carrier_name` лишаються — це денормалізований кеш для відображення, тепер завжди встановлюється сервером із `company_name` власника, а не клієнтом. Було P0 у розділі 17, тепер закрито.

`accepted_at` (nullable, встановлюється сервером у `accept_load`) додано для ETA MVP (розділ 7.7) — це єдина точка відліку "початку рейсу", яку сьогодні має система, за відсутності телематики чи GPS перевізника.

Цільова схема (Фаза 2–3)

Розширення додає компанії (для trust-скорингу й MC/DOT-номерів), офери та історію переговорів, документи з результатами розпізнавання, знімки прогнозів ставки:

```
CREATE TABLE companies (  
  id          BIGSERIAL PRIMARY KEY,  
  legal_name  TEXT NOT NULL,  
  mc_number   TEXT UNIQUE,      -- Motor Carrier number  
  dot_number  TEXT UNIQUE,  
  trust_score NUMERIC(4,1),     -- кеш останнього скору, 0-100  
  created_at  TIMESTAMPTZ DEFAULT now()  
);  
  
CREATE TABLE offers (  
  id          BIGSERIAL PRIMARY KEY,  
  load_id     BIGINT REFERENCES loads(id),  
  carrier_id  BIGINT REFERENCES users(id),  
  price_usd   NUMERIC(10,2) NOT NULL,  
  status      TEXT NOT NULL DEFAULT 'pending', -- pending|countered|accepted|rejected|e  
  source      TEXT NOT NULL DEFAULT 'human',   -- human|ai_agent  
  created_at  TIMESTAMPTZ DEFAULT now()  
);  
  
CREATE TABLE negotiation_messages (  
  id          BIGSERIAL PRIMARY KEY,  
  offer_id    BIGINT REFERENCES offers(id),  
  sender      TEXT NOT NULL,   -- shipper|carrier|ai_agent  
  channel     TEXT NOT NULL,   -- chat|email|sms|voice_transcript  
  body        TEXT NOT NULL,  
  proposed_price NUMERIC(10,2),  
  created_at  TIMESTAMPTZ DEFAULT now()  
);  
  
CREATE TABLE trust_scores (  
  company_id  BIGINT REFERENCES companies(id),  
  score       NUMERIC(4,1) NOT NULL,   -- 0-100  
  factors     JSONB NOT NULL,          -- {"payment_history":..., "insurance_valid":...  
  model_version TEXT NOT NULL,  
  computed_at TIMESTAMPTZ DEFAULT now(),  
  PRIMARY KEY (company_id, computed_at)  
);  
  
CREATE TABLE market_rate_snapshots (  
  lane        TEXT NOT NULL,   -- нап. 'DAL-HOU'  
  equipment_type TEXT NOT NULL,  
  predicted_at TIMESTAMPTZ NOT NULL,  
  horizon_days INT NOT NULL,  
  predicted_usd NUMERIC(10,2) NOT NULL,  
  confidence_low NUMERIC(10,2),  
  confidence_high NUMERIC(10,2),  
  model_version TEXT NOT NULL  
);
```



```
CREATE TABLE documents (  
  id          BIGSERIAL PRIMARY KEY,  
  load_id     BIGINT REFERENCES loads(id),  
  doc_type    TEXT NOT NULL,    -- bol|pod|rate_confirmation|insurance_coi  
  storage_uri TEXT NOT NULL,    -- s3://...  
  extraction  JSONB,           -- структуровані поля з IDP-пайплайну  
  confidence  NUMERIC(4,3),  
  review_status TEXT NOT NULL DEFAULT 'auto', -- auto|needs_review|reviewed  
  created_at  TIMESTAMPTZ DEFAULT now()  
);
```

`loads.embedding vector(768)` додається як колонка pgvector для семантичного пошуку й матчингу (розділ 7.3/7.6) — окрема векторна БД не потрібна, поки обсяг вантажів не вимагає ANN-індексів поза Postgres.

06 Сервіси бекенду

СЕРВІС	ВІДПОВІДАЛЬНІСТЬ	КЛЮЧОВА ТЕХНІКА	СТАТУС
Core Loadboard Service	Користувачі, вантажі, статуси, офери, оплата (майбутнє)	FastAPI + Postgres	MVP
Matching Service	Ранжування відкритих вантажів під профіль і історію перевізника	MVP: детерміністична евристика (розділ 7.3); pgvector + gradient-boosted ranking — ціль	MVP
Pricing Service	Прогноз ринкової ставки на маршруті на N днів вперед	LightGBM / часові ряди, знімки в <code>market_rate_snapshots</code>	R&D
Negotiation Service	LLM-агент, що веде першу комунікацію й торгується в заданих межах	LLM function calling + guardrails (розділ 7.1)	R&D
Trust Service	Скоринг надійності контрагента, флаги подвійного брокериджу	Табличний класифікатор + зовнішні перевірки (FMCSA, страхові)	R&D
Document Intelligence Service	OCR і структурування BOL/POD/rate confirmation	OCR + layout-модель + LLM-екстракція (розділ 7.2)	R&D
Search Service	Пошук вантажів природною мовою	LLM parsing (<code>POST /api/search</code> , розділ 7.6) → структурований фільтр; векторний пошук ще не реалізовано	MVP
ETA Service	Оцінка часу прибуття	MVP: детерміністична евристика на реальній відстані/тривалості через Nominatim+OSRM (розділ 7.7); регресія на телематиці/трафіку/погоді — ціль	MVP
Notification Service	Push/email/SMS про зміну статусу вантажу, нові офери	WebSocket + черга задач	ФАЗА 3

Усі AI-сервіси — окремі деплойменти, що читають зі спільної шини подій і пишуть результат назад у Postgres через власний вузький API-контракт (не мають прямого доступу до таблиць одне одного).

Це свідомо ближче до модульного моноліту з чіткими межами, ніж до «мікросервісів заради мікросервісів» — команда з 2–5 інженерів не обслужить 9 незалежних репозиторіїв; проведені так, щоб їх можна було фізично розрізати пізніше без переписування доменної логіки.


07 AI/ML підсистема

Сім продуктових AI-функцій зі спільною інфраструктурою. Спільний принцип для всіх: **модель ніколи не є єдиною точкою відмови** — кожен сервіс має детерміністичний fallback (порожній список рекомендацій, останню відому ставку, ескалацію людині), і жоден AI-виклик не блокує основний транзакційний шлях (розділ 3).

ФУНКЦІЯ	ПІДХІД	КЛЮЧОВІ ДАНІ	ЛЮДИНА В ІНТЕР'Є
Розумний підбір вантажу MVP	MVP: детерміністична евристика за типом кузова й лейнами (embeddings + gradient boosting — ціль)	Маршрут, тип кузова, історія прийнятих вантажів перевізника	Ні — лише сортування, вибір за перевізником
Прогноз ринкової ставки	Часові ряди / gradient boosting	Історичні ставки по лейнах, паливо, сезонність, попит/пропозиція	Ні — довірчий інтервал показується явно
AI-асистент переговорів	LLM-агент із function calling	Межі ціни від shipper, історія лейну, повідомлення контрагента	Так — ескалація за межами довіри (розділ 7.1)
Скоринг надійності	Табличний класифікатор + правила	Історія платежів, FMCSA-дані, страхові документи, флаги шахрайства	Так — низький скор блокує авто-матчинг, потребує ручного review
Автоматизація документів	OCR + LLM-екстракція	Скан/фото BOL, POD, rate confirmation	Так — нижче порогу впевненості (розділ 7.2)
Пошук природною мовою MVP	LLM parsing → структурований фільтр (векторний пошук — заплановано)	Вільний текстовий запит користувача	Ні — детерміністичний фолбек на пошук за ключовими словами
Прогноз ETA MVP	MVP: детерміністична евристика на реальній відстані/тривалості (регресія на телематиці/трафіку/погоді — ціль)	Реальна відстань/тривалість (Nominatim+OSRM), accepted_at	Ні

7.1 AI-асистент переговорів

Найризикованіша функція продукту: модель веде реальну комунікацію від імені платформи і може «пообіцяти» ціну. Тому це єдиний AI-сервіс із жорстким контуром безпеки, а не просто LLM-викликом.



Мал. 2 — Агент пропонує ціну лише в межах, які задав shipper заздалегідь; вихід за межі або невпевненість моделі завжди веде до ескалації людині, ніколи не до «здогадки» AI.

Чому саме так: LLM за конструкцією не гарантує дотримання числових меж лише інструкцією в промпті — тому перевірка меж винесена в детерміністичний код (`check_bounds()`), а не довірена моделі. Агент може пропонувати формулювання і тон, але не може обійти хардкоджену перевірку суми.

7.2 Автоматизація документообігу

Пайплайн розпізнавання BOL/POD/rate confirmation: `upload` → `OCR/layout` → `LLM-структурування у JSON` → `перевірка впевненості` → `авто-збереження або черга ручної перевірки`. Поле `confidence` з таблиці `documents` (розділ 5) — це мінімум `confidence` по обов'язкових полях (сума, дата, підпис/номер вантажу); нижче порогу (напр. 0.90) документ іде в чергу ручної перевірки замість автоматичного застосування. Кожне ручне виправлення записується як приклад для донавчання/промпт-тюнінгу — цикл зворотного зв'язку описаний у розділі 13.

7.3 Розумний підбір вантажу MVP

Реалізовано: `GET /api/loads/matches` (`api/routes/matching.py`) — детерміністична евристика, без LLM і без ML-моделі. Для перевізника з історією (будь-які вантажі, де він `carrier_id`, незалежно від статусу) кожен відкритий вантаж отримує бал: +3 за збіг типу кузова з раніше виконаними вантажами, +2 за збіг штату `origin` і +2 за збіг штату `destination` із лейнами перевізника;

результат сортується за балом, потім за часом публікації. Перевізник без історії (новий акаунт) отримує звичайний список найновіших відкритих вантажів — той самий запит, що й `/api/loads?status=open` — це свідомий детермінований випадок ("холодний старт"), а не порожня чи зламана відповідь.

Чому не embeddings + gradient boosting одразу: цільова модель нижче потребує реальних поведінкових даних (історія прийнять/відмов у масштабі), яких у демо немає — навчання на кількох сід-вантажках дало б випадковий шум, а не сигнал. Той самий принцип, що й у NL Search (розділ 7.6): спершу детерміністична версія, що дає реальну користь сьогодні, апгрейд до моделі — коли з'являться дані, варті навчання.

7.4–7.7 Інші AI-сервіси — принципи проєктування

Matching – цільова модель (7.3)

Ембединги вантажу (маршрут, тип кузова, вага, час) + профіль перевізника (домашня база, вподобані лейни, історія прийняття/відмов) → cosine-подібність як базовий сигнал, gradient boosting поверх — для калібрування під фактичну конверсію в прийняття. Замініть евристику вище, коли зберуться реальні дані.

Pricing (7.4)

Прогноз на лейн-рівні (origin-dest-equipment), горизонт 1–7 днів, з довірчим інтервалом, а не точковим числом — платформа явно показує невпевненість, а не видає її за факт.

Trust Scoring (7.5)

0–100 з поясненими факторами (JSONB `factors`), не «чорна скринька» — перевізник/shipper бачить, чому скор такий, і може оскаржити. Низький скор не банить автоматично, а знижує пріоритет у матчингу і додає попередження.

NL Search (7.6) MVP

Реалізовано: `POST /api/search` (`core/llm.py`) шле запит у Claude Haiku 4.5 через

`messages.parse()` зі структурованим виходом (`SearchFilter`:

`origin/destination/equipment_type/price_max/weight_min/weight_max`), результат застосовується як звичайні SQLAlchemy-фільтри поверх `loads`. Векторний пошук за смисловою близькістю (embeddings) — ще не реалізовано, лишається ціллю Фази 2/3. Сам виклик до LLM вимкнений за

замовчуванням прапорцем `NL_SEARCH_ENABLED=false` у `.env` — щоб не витратити кредити Anthropic, поки хтось свідомо не увімкне; `core/llm.py` перевіряє цей прапорець ще до звернення до ключа. Якщо прапорець вимкнено, ключ `ANTHROPIC_API_KEY` відсутній, виклик до Anthropic падає

або на акаунті скінчилися кредити — фолбек не «форма з фільтрами» і не нефільтрований список, а простий пошук за ключовими словами (`_keyword_filter`): кожне слово запиту через `ILIKE` має збігтися хоч в одній із колонок `title/origin/destination/equipment_type`; ендпоінт ніколи не повертає помилку через відмову LLM і завжди хоч якось фільтрує.

ETA (7.7) MVP

Реалізовано: `GET /api/loads/{id}/eta` (`core/eta.py`) — детерміністична евристика, без ML-моделі. Геокодує `origin/destination` через Nominatim, отримує реальну відстань і тривалість руху

через OSRM (ті самі провайдери, що й карта на фронтенді, тут викликаються з бекенда), і розширює звичайну (легковою) тривалість OSRM у діапазон `[drive_hours_min, drive_hours_max]` (×1.3) — наближення для типових обов'язкових зупинок на відпочинок під час далекого рейсу. Коли

перевізник бере вантаж (`loads.accepted_at`, встановлюється сервером у `accept_load`), ендпоінт додає цей діапазон до `accepted_at` і повертає вікно прибуття (`eta_earliest`/`eta_latest`); до

прийняття — лише оцінку часу в дорозі, бо немає точки відліку відправлення. На сторінці деталей вантажу відображається як панель «Estimated arrival» після прийняття вантажу.

Чому не справжня модель одразу: цільова модель потребує GPS-телематики перевізника, живого трафіку й погоди — нічого з цього в демо немає. Той самий принцип, що й у Matching (7.3) та NL Search (7.6): спершу детерміністична версія, що дає реальну користь сьогодні.

Спільне для всіх

Кожна модель має версію (`model_version`), логується вхід/вихід для офлайн-оцінки, і має задокументований fallback на детермінізм при відмові.

7.8 Спільна AI-інфраструктура

- **LLM Gateway** — єдина точка виклику моделей: абстрагує провайдера (можливість перемкнутись між моделями без зміни коду сервісів), рахує вартість tokenів на запит, застосовує тайм-ауту й fallback на меншу/дешевшу модель при відмові основного провайдера.
- **Редагування PII перед відправкою назовні.** Персональні дані водія/контактні дані контрагента маскуються перед тим, як текст іде до стороннього LLM-провайдера, і відновлюються після відповіді — вимога для документообігу з ПІБ водіїв і номерами телефонів.
- **Реєстр промптів і eval-набори.** Кожен промпт версіонується; зміна промпту прогонюється проти зафіксованого набору реальних кейсів (regression suite для AI, а не лише для коду) перед викаткою.
- **Canary rollout моделей.** Нова версія моделі/промпту спершу отримує невелику частку трафіку, порівнюється за метриками якості й вартості, і лише потім масштабується на 100%.
- **Бюджет вартості й circuit breaker.** Ліміт витрат на AI-виклики за період; при перевищенні — деградація до дешевших/детерміністичних шляхів, а не мовчазне зростання рахунку.
- **Feature Store.** Спільні ознаки (історія лейну, поведінка перевізника) обчислюються один раз і перевикористовуються Matching, Pricing і Trust сервісами замість дублювання логіки.

08 API

Конвенції

- Базовий шлях `/api`, JSON тіла запитів/відповідей, помилки — `{"detail": "..."} (стандартний формат FastAPI/Pydantic).`
- Автентифікація — заголовок `Authorization: Bearer <JWT>`.
- Публічна специфікація автогенерується FastAPI: `/docs` (Swagger UI) та `/openapi.json`.
- Заплановано на Фазу 2: версіонування шляху (`/api/v1/...`), курсорна пагінація (`?cursor=`) для списків, ідемпотентні ключі для `POST /offers`.

Реалізовані ендпоінти (MVP)

МЕТОД	ШЛЯХ	ОПИС	AUTH
GET	/api/health	Перевірка живості сервісу	—
POST	/api/auth/register	Реєстрація (email, пароль, компанія, роль) — видає пару access+refresh	—
POST	/api/auth/login	Вхід — видає пару access-JWT (15 хв) + refresh-токен	—
GET	/api/auth/me	Поточний користувач за токеном	Bearer
POST	/api/auth/refresh	Обміняти дійсний refresh-токен на нову пару (ротація, розділ 9)	—
POST	/api/auth/logout	Відкликати refresh-токен	—
GET	/api/loads ?status=	Список вантажів, опційний фільтр	—
GET	/api/loads/{id}	Деталі одного вантажу — сторінка деталей на фронтенді	—
POST	/api/loads	Публікація вантажу — тільки роль shipper, shipper_id береться з токена	Bearer
POST	/api/loads/{id}/accept	Взяти вантаж напряму — тільки роль carrier, carrier_id береться з токена	Bearer
POST	/api/loads/{id}/complete	Позначити завершеним — лише shipper вантажу або carrier, що його взяв	Bearer
POST	/api/search	Пошук вантажів природною мовою — LLM-парсинг у фільтр (розділ 7.6), фолбек на пошук за ключовими словами	—
GET	/api/loads/matches	Розумний підбір вантажу — детерміністична евристика під історію перевізника (розділ 7.3)	Bearer, роль carrier
GET	/api/loads/{id}/eta	Прогноз часу прибуття — детерміністична евристика на реальній відстані/тривалості (розділ 7.7)	—

Заплановані ендпоінти (Фаза 2–3)

МЕТОД	ШЛЯХ	ОПИС
GET	/api/rates/forecast	Прогноз ставки за лейном/типом кузова/датою
POST	/api/loads/{id}/offers	Створити офер (людиною або AI-агентом)
POST	/api/offers/{id}/counter	Контрпропозиція
GET	/api/companies/{id}/trust-score	Скор надійності з поясненими факторами
POST	/api/loads/{id}/documents	Завантажити BOL/POD/rate confirmation
WS	/ws/notifications	Realtime-сповіщення: нові офери, зміни статусу

09 Автентифікація, авторизація й ролі

Сьогодні: email+пароль → `bcrypt`-хеш → короткоживучий access-JWT (HS256, `sub`=email, 15 хв за замовчуванням) з `python-jose` + окремий refresh-токен (опаковий випадковий рядок, зберігається в БД лише як SHA-256-хеш, таблиця `refresh_tokens`). Ротація на кожному використанні (`POST /api/auth/refresh`) — старий refresh-токен помирає в момент видачі нового, тож повторне використання вкраденого токена після того, як легітимний клієнт уже зробив refresh, — відхилене повторне використання, а не тиха друга сесія. `POST /api/auth/logout` відкликає токен явно. Сам access-JWT відкликати не можна (він статичний за конструкцією), але коротке 15-хвилинне вікно замість 7 днів суттєво звужує вікно ризику. Фронтенд оновлює access-токен у фоні непомітно для користувача (`AuthContext.tsx`). Обидва токени зберігаються в `localStorage` — це усвідомлений компроміс, не цільовий дизайн (див. нижче).

РОЛЬ	МОЖЕ СЬОГОДНІ	ЦІЛЬ (ФАЗА 2+)
shipper	Публікувати вантаж	+ бачити офери, вести переговори, бачити trust-скор перевізника
carrier	Брати відкритий вантаж	+ AI-рекомендації, робити контрпропозиції, завантажувати POD
dispatcher (enterprise)	—	Керує кількома вантажівками/водіями від імені carrier-компанії
admin	—	Модерація, перегляд журналу аудиту, ручний review документів/скорингу

Цільові покращення: refresh-токен через httpOnly cookie замість `localStorage` (усуває XSS-читання, потребує CSRF-захисту навзаєм), відкликання через deny-list у Redis замість `redis` Postgres (масштаб), MFA для enterprise-акаунтів, SSO (OAuth2/OIDC) для великих shipper-клієнтів, окремі API-ключі з обмеженими scope для інтеграцій (TMS-конектори).

10 Безпека

ОБЛАСТЬ	ПОТОЧНИЙ СТАН	ЦІЛЬ
Секрети	<code>JWT_SECRET</code> зі змінної середовища, дефолт <code>"dev-secret-change-me"</code> у коді	Секрет-менеджер (Vault/AWS Secrets Manager), без дефолтів у коді
CORS	Явний allowlist через <code>CORS_ORIGINS</code>	Домени продакшн-фронтенду замінюють дефолтний dev-origin
Rate limiting	Відсутній	На рівні API Gateway, окремо жорсткіше на <code>/auth/*</code>
Авторизація на рівні ресурсу	Є на трьох mutating-ендпоінтах вантажів (розділ 17, закрито)	Те саме покриття по мірі появи нових ресурсів (offers, documents)
PII та документи	Н/З — документів ще немає	Шифрування в спокої (S3 SSE), маскування PII перед LLM-викликами (розділ 7.8)
Аудит	Відсутній	<code>audit_log</code> : хто/що/коли, окремо — усі AI-повідомлення від імені платформи (розділ 7.1)
Залежності	Не скануються	Dependabot/ <code>pip-audit</code> у CI, блокування критичних CVE
Пентест	Не проводився (демо-стадія)	Перед публічним запуском і раз на рік/після значних змін

11 Інфраструктура та DevOps

Сьогодні: `docker-compose.yml` піднімає три контейнери — `db` (Postgres 16 з healthcheck), `backend` (FastAPI, ретраї підключення до БД при старті), `frontend` (Vite dev-сервер). Один хост, без окремих середовищ.

СЕРЕДОВИЩЕ	ПРИЗНАЧЕННЯ	СТАТУС
local	Розробка через <code>docker compose up</code>	MVP
staging	Перевірка перед релізом, синтетичні дані	ФАЗА 2
production	Kubernetes, окремі node pool для Core і AI-воркерів (AI-воркери — з доступом до GPU/вищим CPU-лімітом і власним автоскейлінгом за чергою подій)	ФАЗА 3

CI/CD (Фаза 2): GitHub Actions — лінт (ruff/eslint) → тести → білд Docker-образів → пуш у реєстр → деплой у staging автоматично, у production через ручне затвердження. **Резервне копіювання:** щоденний снапшот Postgres + point-in-time recovery до 7 днів; документи в об’єктному сховищі — versioning увімкнено для захисту від випадкового перезапису.

12 Продуктивність і масштабованість

- Кешування.** Redis для «гарячого» списку відкритих вантажів і результатів прогнозу ставки (TTL кілька хвилин — прогноз не повинен перераховуватись на кожен рендер списку).
- Асинхронні задачі.** Важкі AI-виклики (переговори, OCR) йдуть через чергу (Celery/RQ поверх Redis, пізніше — Kafka), не в request-response циклі API.
- Індекси БД.** `loads(status, created_at)` складений індекс для основного списку; `loads(origin, destination, equipment_type)` для матчингу; pgvector HNSW-індекс на `embedding`.
- Read-репліки.** Читання списку вантажів і аналітики — з репліки, запис — лише на primary, коли навантаження це виправдає.
- CDN.** Статика фронтенду й завантажені документи (через підписані URL) — за CDN, не проксуються бекендом.

МЕТРИКА	ЦІЛЬОВИЙ БЮДЖЕТ
Список вантажів, p95	< 200 мс
Публікація вантажу, p95	< 300 мс
AI-матчинг (асинхронний), p95	< 3 с
Перший хід Negotiation Agent, p95	< 8 с
Доступність Core API	99.9%

13 Спостережуваність

Сьогодні — лише stdout-логи `uvicorn`, нічого структурованого. Цільовий стек:

- **Логи** — структуровані (JSON), з `request_id`, що проходить через Gateway → Core → подію → AI-сервіс, для наскрізного трасування одного запиту користувача.
- **Метрики** — Prometheus: латентність по ендпоінтах, довжина черги подій, вартість AI-викликів у доларах на добу.
- **Трейсинг** — OpenTelemetry, окремо позначені AI-спани (модель, кількість токенів, латентність провайдера).
- **AI-специфічна спостережуваність**: eval-пайплайн на sample реальних кейсів після кожної зміни промπτу/моделі; дрейф якості (частка ескалацій Negotiation Agent людині — раптове зростання сигналізує про регресію); черга людського review для документів і скорингу як явний UI, а не побічний ефект.
- **Цикл зворотного зв'язку**. Кожне ручне виправлення (диспетчер поправив офер AI, людина виправила поле документа) записується як приклад для наступного eval-набору й потенційного донавчання/промπτ-тюнінгу.

14 Зовнішні інтеграції

КАТЕГОРІЯ	НАВІЩО	ВИКОРИСТОВУЄТЬСЯ В
Картографія / трафік	Відстань, час у дорозі, затори	ETA, Matching (порожній пробіг)
Погода	Коригування ETA, ризик затримки	ETA
ELD / телематика перевізника	Реальна GPS-позиція, HOS-ліміти водія	ETA, Trust
FMCSA / кредитні бюро	MC/DOT-верифікація, страхове покриття, історія претензій	Trust Scoring, онбординг компанії
e-Signature	Підписання rate confirmation без обміну PDF поштою	Document Intelligence, офери
Платежі / факторинг	Швидка оплата перевізнику після POD (майбутня монетизація)	Завершення вантажу
SMS / email провайдер	Сповіщення, канал для Negotiation Agent	Notification, Negotiation
DAT/Truckstop (публічні API, де доступно)	Холодний старт ринкових даних для Pricing до накопичення власної історії	Pricing Service

15 Тестування та якість

РІВЕНЬ	ІНСТРУМЕНТ	ЩО ПОКРИВАЄ	СТАТУС
Unit (бекенд)	pytest	Схеми, бізнес-правила (напр. переходи статусу вантажу)	ФАЗА 2
Unit (фронтенд)	Vitest + Testing Library	Компоненти, AuthContext	ФАЗА 2
Інтеграційні	pytest + тестовий Postgres у Docker	Ендпоінти API наскрізь через БД	ФАЗА 2
E2E	Playwright	Реєстрація → публікація → взяття вантажу	ФАЗА 3
AI-eval	Власний харнес поверх зафіксованого набору кейсів	Якість Negotiation/Matching/Trust — регресія перед кожним релізом промпту чи моделі	R&D
Навантажувальні	k6/Locust	Латентність під пік-навантаженням, черга подій під бекпресурою	ФАЗА 3

Сьогодні: `backend/tests` покриває health-check, auth/роль/власність на трьох мутуючих ендпоінтах вантажів, `POST /api/search` (виклик Anthropic мокається на місці імпорту — тести детерміністичні, без мережі й без `ANTHROPIC_API_KEY`), `GET /api/loads/matches` (ранжування, роль, холодний старт), `GET /api/loads/{id}` (деталі, 404, регресійний тест на те, що `{load_id:int}` не "проковтує" `/matches`) і `GET /api/loads/{id}/eta` (виклик Nominatim/OSRM мокається так само, як Anthropic у тестах пошуку — 404, деградація при недоступному роутингу, вікно прибуття лише для прийнятих вантажів). Фронтенд — жодного файлу `*.test.*`. Наступний пріорітет: перехід статусів вантажу (`open-accepted-completed`), оскільки саме там зараз відомий розрив (розділ 17).

16 Технічна дорожня карта

ФАЗА	ТЕХНІЧНА ЦІЛЬ	АІ-ФІЧІ, ЩО ВМИКАЮТЬСЯ
MVP ГОТОВО	Транзакційний каркас: auth, вантажі, статуси	Пошук природною мовою (базова версія — структурований фільтр, без векторного пошуку) і розумний підбір вантажу (базова версія — детерміністична евристика, без ML) ГОТОВО
Фаза 2 3–4 МІС	Авторизація на рівні ресурсу, тести, CI, черга задач, об’єктне сховище, pgvector	Embeddings + gradient boosting для Matching, векторний пошук поверх NL Search, rate limiting/cost cap для LLM-викликів
Фаза 3 5–9 МІС	Kubernetes, шина подій, спостережуваність, мобільний застосунок	Прогноз ставки, скоринг надійності, автоматизація документів, ETA
Фаза 4 R&D	Multi-region, SSO для enterprise, платіжний рейл	AI-асистент переговорів (найризикованіша фіча — останньою, після довіри користувачів до простіших AI-функцій)

Порядок навмисний: Negotiation Agent — найцінніша, але й найризикованіша фіча (модель говорить від імені платформи з реальними грошима на кону). Вона йде останньою, коли інфраструктура guardrails, аудиту й ескалації (розділ 7.1, 13) вже перевірена на менш ризикованих AI-функціях.

17 Технічний борг і відомі обмеження

#	ПРОБЛЕМА	ВПЛИВ	ПРІОРИТЕТ
1	POST /api/loads , /accept , /complete не перевіряли автентифікацію чи роль — закрито: усі три вимагають Beager-токен і перевіряють роль (розділ 8)	Було: будь-хто без токена міг публікувати/забирати/закривати вантажі	ЗАКРИТО
2	loads.shipper_name / carrier_name — вільний текст, не FK на users — закрито: додано <code>shipper_id / carrier_id</code> (розділ 5)	Було: неможливо перевірити власність вантажу; дані легко підробити	ЗАКРИТО
3	JWT без refresh і без відкликання — закрито: короткоживучий (15 хв) access-JWT + окремий revocable refresh-токен з ротацією (розділ 9, <code>backend/app/core/security.py</code>). Дефолтний <code>JWT_SECRET</code> у коді лишається — свідомий виняток лише для демо (<code>security.md</code>), не забути замінити перед будь-яким спільним/staging-оточенням (див. README)	Було: вкрадений токен дійсний 7 днів без способу його відкликати	ЗАКРИТО
4	CORS <code>allow_origins=["*"]</code>	Прийнятно для демо, неприйнятно для продакшну з реальними даними	P1
5	Схема БД створюється через <code>Base.metadata.create_all</code> , без міграцій — закрито: Alembic (<code>backend/migrations/</code>), застосовується перед стартом застосунку в усіх середовищах (розділ 4)	Було: немає керованого шляху еволюції схеми в продакшн-даних	ЗАКРИТО
6	Тести бекенду — health-check, auth/ownership на <code>loads</code> , <code>/api/search</code> , <code>/api/loads/matches</code> , <code>GET /api/loads/{id}</code> і <code>GET /api/loads/{id}/eta</code> (24 тести); фронтенд — жодного	Більшість бізнес-логіки досі без регресійного захисту	P1
7	Немає rate limiting на <code>/api/auth/*</code>	Вразливість до brute-force підбору пароля	P2
8	4 із 7 AI-сервісів — поки що специфікація, не код (реалізовано NL Search, Matching і ETA MVP, розділи	Основна цінність продукту для	ВІДКРИТО

#	ПРОБЛЕМА	ВПЛИВ	ВІЗНАЧЕННЯ
	7.3/7.6/7.7 — усі три детерміністичні, без ML/embeddings)	інвестора здебільшого ще не побудована	
9	<code>POST /api/search</code> без rate limiting і без per-request/per-period cost cap на виклики Anthropic (розділ 7.8 — «circuit breaker» ще не реалізовано)	Будь-хто без автентифікації може ініціювати необмежену кількість платних LLM-викликів	P2
10	<code>frontend/src/geocode.ts</code> викликає Nominatim напряду з браузера, без бекенд-проксі й без rate limiting поза кешем в пам'яті на сесію — політика Nominatim обмежує безкоштовне використання ~1 запитом/сек	Реальний продакшн-трафік ризикує блокуванням IP з боку Nominatim	P2
11	<code>frontend/src/routing.ts</code> викликає публічний demo-сервер OSRM напряду з браузера — той самий тип обмеження, що й пункт 10: без бекенд-проксі, без rate limiting поза кешем у сесії; сервер офіційно не призначений для продакшн-навантаження	Немає SLA/гарантії доступності для реального трафіку	P2
12	<code>backend/app/core/eta.py</code> також викликає Nominatim і публічний demo-сервер OSRM напряду (з бекенда, для ETA MVP, розділ 7.7) — той самий тип обмеження, що й пункти 10–11, але тепер і серверний трафік; кеш у пам'яті процесу (не за сесію) частково пом'якшує навантаження на ці сервіси, але не є заміною реальному rate limiting чи платному провайдеру	Той самий ризик блокування/відсутності SLA, тепер із серверного, а не лише клієнтського боку	P2
13	Refresh-токен (розділ 9) зберігається в <code>localStorage</code> , як і access-токен до нього — читається будь-яким JS на сторінці. Ротація (пункт 3 вище) обмежує вкрадений токен одним використанням, але не запобігає самій крадіжці; цільовий дизайн — httpOnly cookie, яку клієнтський JS взагалі не бачить, разом із CSRF-захистом	XSS будь-де на сайті може вкрати сесію на весь термін дії refresh-токена (30 днів за замовчуванням), а не лише на 15 хв access-токена	P2

Пункти 1–2 закрито до початку роботи над AI, як і планувалося: без FK-зв'язку вантажу з власником неможливо було б коректно побудувати ані trust scoring, ані персоналізований matching, ані журнал переговорів — уся AI-підсистема з розділу 7 спирається саме на цей зв'язок.

